# Processamento de Linguagens e Compiladores Pré-processador para LATEX

Relatório de Desenvolvimento

André Sá (76361)

João Bastos (47419)

Pedro Sá (78164)

14 de Outubro de 2018

Resumo
O trabalho apresentado consiste na criação de um facilitador à criação e edição de documentos em LATEX recorrendo a uma linguagem mais simplificada e um pré-processador que faz a correspondente "tradução" para LATEX.

# Conteúdo

1	Introdução 3						
	1.1	Descrição informal do problema					
	1.2	Estrutura do Relatório					
2	Ling	guagem Simplificada					
	2.1	Acentos e Cedilhas					
	2.2	Cabeçalhos e Preâmbulos					
		2.2.1 Tipo de Documento					
		2.2.2 Título e Autor					
		2.2.3 Índices					
		2.2.4 Secções e Sub-secções					
	2.3	Texto formatado					
		2.3.1 Itálico					
		2.3.2 Bold					
	2.4	Texto não formatado					
	2.5	Listas					
		2.5.1 Itens					
		2.5.2 Descritivas					
		2.5.3 Numeradas					
	2.6	Macros					
3	Concepção/desenho da Resolução						
	3.1	Início e Fim do documento					
	3.2	Conteúdo do Documento					
	3.3	Bold e Italic					
	3.4	4 Verbatim					
	3.5	8.5 Listas					
	3.6	Secções e Sub-secções					
4	Cor	ncepção/desenho da Resolução					
	4.1	Início e Fim do documento					
	4.2	Conteúdo do Documento					
	4.3	Bold e Italic					
	4.4	Verbatim					
	4.5	Listas					
	4.6	Secções e Sub-secções         12					
	17	Estruturas da Dados					

	4.8	Algori	tmos	13
5	Coc	lificaçã	o e Testes	14
	5.1	Testes	realizados e Resultados	14
		5.1.1	Doctype, Titl e Autor	14
		5.1.2	Caracteres Especiais	14
		5.1.3	Lista Numeradas	15
		5.1.4	Lista de Itens	15
		5.1.5	Lista Descritivas	15
		5.1.6	Verbatim	15
		5.1.7	Níveis de secção	15
6	Con	ıclusão		17
$\mathbf{A}$	Cóc	ligo do	Programa	18

# Introdução

#### 1.1 Descrição informal do problema

O LªTEX é um sistema tipográfico, bastante útil e completo, para a produção de todo o tipo de documentos. Porém, a edição do documento pode-se tornar morosa devido ao peso das marcas (comandos do LªTEX) necessárias para anotar o texto.

O trabalho realizado teve como premissa precisamente facilitar a escrita de documentos em IATEX simplificando certas anotações de forma, conteúdo ou formato. Assim, foi criada uma linguagem mais simples baseada na ferramenta PPP<sup>1</sup>. De seguida recorrendo à ferramenta Flex, criamos um processador que transforme a notação referida em IATEX.

#### 1.2 Estrutura do Relatório

Neste relatório começamos com a Introdução (Capítulo 1) onde, de uma forma breve tentamos descrever o enquadramento do documento e a estrutura do mesmo.

No capítulo 2 explicamos em que consiste a Linguagem Simplificada e no capítulo seguinte (Capítulo 3) a forma como desenvolvemos a ferramenta que utilizará as regras dessa linguagem para criar o ficheiro LATEX.

 $O\ Capítulo\ 4\ ser\'a composto\ pelos\ testes\ executados\ e\ no\ Capítulo\ 5\ a\ Conclus\~ao\ onde\ fazemos\ uma\ an\'alise\ ao\ trabalho\ executado.$ 

Por último o documento tem o apêndice onde foi introduzido o código fonte do ficheiro Lex.

<sup>&</sup>lt;sup>1</sup>PPP (Ptext PreProcessor) - http://www4.di.uminho.pt/ jcr/AULAS/plc2008/tp1/ppp.html

# Linguagem Simplificada

Neste capítulo indicaremos a sintaxe definida nesta **Linguagem Simplificada**, doravante representada por LS, para os diferentes aspectos. Em cada caso iremos apresentar na forma de tabelas a sintaxe na LS e a correspondência em  $\LaTeX$ 

#### 2.1 Acentos e Cedilhas

Esta será a maior mais-valia desta ferramenta devido à acentuação e cedilhas presentes na língua portuguesa que obrigavam em LATEX à constante notação sobre palavras travando a fluidez na escrita.

LS	ĿΤΕΧ
á	\'a
à	\'a
$\tilde{\mathrm{a}}$	\~a
$\hat{\mathbf{a}}$	\^a
é	\'e
ê	\^e
í	\{\i}
Í	\'I
ó	\'0
õ	\~o
ô	\^o
ú	\'u
ü	\"u
ç	\c{c}
Ć	\c{C}

### 2.2 Cabeçalhos e Preâmbulos

#### 2.2.1 Tipo de Documento

Ao iniciar o documento, o IATEX necessita saber qual o layout mediante o tipo de documento que pretendemos. Na LS usaremos a seguinte sintaxe sendo o comando introduzido no início da linha:

LS	I	AT <sub>E</sub> X		
=doctype=[tipo de d	locumentol \	documentclass{tipo	de	documento}

Foi definido que o corpo do documento só será iniciado quando for encontrada a primeira linha em branco pelo que antes disso cabe ao utilizador começar o ficheiro com introdução do tipo de documento, título e autores.

#### 2.2.2 Título e Autor

O título e autores do documento são escritos no início de linha com a seguinte sintaxe:

LS	$ \mathbb{P}_{\mathrm{LX}} $
=title=[título]	\title{título}
<pre>=author=[autor1 \and autor2 \and]</pre>	\author{autor1 \and autor2 \and}

#### 2.2.3 Índices

O índice é gerado no local onde o respectivo comando é introduzido sendo possível definir o local no documento onde o pretendemos, no entanto de momento apenas é possível gerar um índice por documento. O comando deverá ser introduzido no ínicio da linha. A sintaxe é a seguinte:

#### 2.2.4 Secções e Sub-secções

As secções e os diversos níveis de sub-secções são introduzidos iniciando uma linha com os "="seguido do nome da secção ou subsecção, sendo a sua numeração gerada automaticamente.

O nível da secção corresponde ao número de "="'s introduzidos.

Nível	LS	Ŀ <sup>™</sup> EX
1	=capítulo	\chapter{capítulo}
2	==secção	\section{secção}
3	===sub-secção	\subsection{sub-secção}
4	====sub-subsecção	\subsubsection{sub-subsecção}
5	====parágrafo	\paragraph{parágrafo}

#### 2.3 Texto formatado

Qualquer pedaço de texto pode ser formatado em Italico ou Bold. Para tal colocamos o texto que pretendemos formatar dentro dos respectivos comandos tal como exemplificamos de seguida.

#### 2.3.1 Itálico

#### 2.3.2 Bold

#### 2.4 Texto não formatado

Para quando é necessário ter como input exactamente o que foi escrito o LATEX tem o comando Verbatim que optamos por simplificar da seguinte forma:

#### 2.5 Listas

Existem três tipos de listas suportadas pela LS. Cada um destes comandos são iniciados por ":"no final de uma linha. Sendo que nos últimos

#### 2.5.1 Itens

Utilizaremos uma descrição por itens para descrever este comando:

- Iniciado por ":"no final de uma linha;
- Cada item será iniciado no ínicio de cada linha por "." seguido de um caracter diferente de "["ou dígito;
- Termina com o caracter "#".

#### 2.5.2 Descritivas

Utilizaremos uma lista descritiva para descrever este comando:

Primeiro Iniciado por ":"no final de uma linha;

Segundo Cada item será iniciado no ínicio de cada linha por "." seguido de uma ou mais palavras entre "["e"]";

Terceiro Termina com o caracter "#".

#### 2.5.3 Numeradas

Utilizaremos uma lista numerada para descrever este comando:

- 1. Iniciado por ":"no final de uma linha;
- 2. Cada item será inicado no ínicio de cada linha por "." seguido de um dígito;
- 3. Termina com o caracter "#".

#### 2.6 Macros

Foram definidas duas macros relacionadas com indicador de ordem em feminino e masculino. Bastará escrever o que se pretende como input que a tradução em LATEX será feita.

#### LS LATEX

- 8° 8\textordmasculine
- 11<sup>a</sup> 11\textordfeminine

# Concepção/desenho da Resolução

Neste capítulo iremos descrever a concepção/desenho do analisador léxico iniciando cada secção com um pequeno resumo seguido do código referido.

#### 3.1 Início e Fim do documento

No ficheiro flex elaborado optamos por manipulação directa da stack de estados utilizando as funções yy\_push\_state e yy\_pop\_state. Para tal introduzimos "%option stack" para além dos estados por nós definidos, como se pode verificar na Figura 4.9.



Figura 3.1: Estados

Como podemos verificar pela Figura 4.10, ao iniciar, o analisador léxico encontrará a indicação do tipo de documento, titulo e autores e só após encontrar a primeira linha em branco irá passar para o estado BODY que vai conter todo o conteúdo do documento. Encontrando o EOF é introduzido o comando para o fim do documento em IATEX (Figura 4.11).

#### 3.2 Conteúdo do Documento

Já dentro do estado BODY, ou seja, dentro do conteúdo do documento, o analisador léxico irá verificar se encontra correspondência para as restantes anotações de forma, conteúdo ou formato que iremos apresentar de seguida. Caso tenha correspondência é encaminhado para o estado devido (Figura 4.12). Caso no início de uma linha encontre "=indice="será impresso o comando \tableofcontents que introduz o índice nesse mesmo local.

```
^\s*$ {
    /*
    * An empty line starts the body of the document,
    * so all the headers must come before any empty line
    */
    printf("\\begin{document}");
    stpush(BODY);
}

^=author=\[ stpush(AUTHOR);
    ^=doctype=\[ stpush(DOCTYPE);
    ^=title=\[ stpush(TITLE);
    <AUTHOR>[^\]\n]+ printf("\\author{%s}", yytext);
    <TITLE>[^\]\n]+ printf("\\title{%s}", yytext);
<TITLE,AUTHOR,DOCTYPE>\]$ stpop();
```

Figura 3.2: Estados DOCTYPE, TITLE, AUTHOR e BODY

```
<<EOF>> {
    printf("\end{document}");
    /* Se nao acabarmos a funcao, o programa fica em loop */
    return 0;
}
```

Figura 3.3: Fim do documento.

```
<BODY>^=indice= { printf("\\tableofcontents");}

<BODY>\\bverb[ \n\t] { printf("\\begin{\verbatim}"); stpush(\VERBATIM); }

<BODY>^#+ { nh = yyleng; stpush(BODY_HEADER); }

<BODY>:/\n\.[0-9 { printf("\\begin{\text{itemize}\"); stpush(LIST_ITEMIZE); }

<BODY>:\\n\\[ { printf("\\begin{\text{description}\"); stpush(LIST_ENUMERATE); }

<BODY>\\bf\{ { printf("\\text{it}\"); stpush(BOLD); }

<BODY>\\it\{ { printf("\\text{it}\"); stpush(ITALIC); }

<BODY>.|\n

\ECHO;
```

Figura 3.4: Estado BODY e encaminhamento para os diferentes estados.

#### 3.3 Bold e Italic

Nestes 2 casos é feita uma simples substituição dos comandos e escrito tudo o que se encontra entre chavetas (Figura 4.5).

Figura 3.5: BOLD e ITALIC.

#### 3.4 Verbatim

Depois de o analisador léxico encontrar o comando de inicialização substitui pelo correspondente em LATEX e faz ECHO até encontrar o comando de finalização que também substitui pelo correspondente (Figura 4.6).

Figura 3.6: VERBATIM.

#### 3.5 Listas

No estado BODY é encontrada a condição de inicialização de cada um dos três tipos de lista e impresso o respectivo comando de início. Daí o analisador léxico entra no respectivo estado e adiciona os itens no formato pretendido. Ao encontrar o "#"imprime o comando de fecho do comando. Dentro destes três estados também se procura correspondência com os comandos de formatação itálico e bold de forma a poder ser aplicado também em listas (Figura 4.7).

```
<LIST_ITEMIZE>^\.\s* { printf("\\item "); }
<LIST_ENUMERATE>^\.[0-9]+\s* { printf("\\item "); }
<LIST_DESCRIPTION>^\.\[ { printf("\\item "); }
<LIST_ENUMERATE,LIST_ITEMIZE,LIST_DESCRIPTION>\\into\{ { printf("\\textbf{"); stpush(BOLD); }
<LIST_ENUMERATE,LIST_ITEMIZE,LIST_DESCRIPTION>\\into\{ { printf("\\textbf{"); stpush(BOLD); }
<LIST_ENUMERATE.\ST_ITEMIZE,LIST_DESCRIPTION>\\into\{ { printf("\\textbf{"); stpush(ITALIC); }

<LIST_ENUMERATE>^\s*=\s*$ { printf("\\end{\text{temize}"); stpop(); }
<LIST_DESCRIPTION>^\s*=\s*$ { printf("\\end{\text{temize}"); stpop(); }
<LIST_DESCRIPTION>^\s*=\s*$ { printf("\\end{\text{description}"); stpop(); }
```

Figura 3.7: Listas.

#### 3.6 Secções e Sub-secções

Existe um limite para os níveis de secções que podem ser criadas. Para resolver esse problema criamos uma função que, com auxílio de um apontador para um array de Strings, permite saber que nível pretendemos para imprimir o comando correcto e quando atinge o seu limite (Figura 4.8.

```
/* Supported LaTeX header tags */
static const char * chaps[] = {
    "chapter",
    "section",
    "subsection",
    "paragraph",
    "subparagraph",
};

/* Number of supported LaTeX header tags */
static const unsigned nc = sizeof(chaps) / sizeof(*chaps);

/* Header level, 0-nc */
int nh = 0;

*}

(a)

<BODY_HEADER>[^#\n] * {
    /* Make sure `nh` is in bounds */
    if (((unsigned) — nh) >= nc)
        nh = nc - 1;
    printf("\\%s{%s}\", chaps[nh], yytext);
    nh = 0;
    stpop();
}

(b)
```

Figura 3.8: BODY\_HEADER

# Concepção/desenho da Resolução

Neste capítulo iremos descrever a concepção/desenho do analisador léxico iniciando cada secção com um pequeno resumo seguido do código referido.

#### 4.1 Início e Fim do documento

No ficheiro flex elaborado optamos por manipulação directa da stack de estados utilizando as funções yy\_push\_state e yy\_pop\_state. Para tal introduzimos "%option stack" para além dos estados por nós definidos, como se pode verificar na Figura 4.9.



Figura 4.1: Estados

Como podemos verificar pela Figura 4.10, ao iniciar, o analisador léxico encontrará a indicação do tipo de documento, titulo e autores e só após encontrar a primeira linha em branco irá passar para o estado BODY que vai conter todo o conteúdo do documento. Encontrando o EOF é introduzido o comando para o fim do documento em IATEX (Figura 4.11).

#### 4.2 Conteúdo do Documento

Já dentro do estado BODY, ou seja, dentro do conteúdo do documento, o analisador léxico irá verificar se encontra correspondência para as restantes anotações de forma, conteúdo ou formato que iremos apresentar de seguida. Caso tenha correspondência é encaminhado para o estado devido (Figura 4.12). Caso no início de uma linha encontre "=indice="será impresso o comando \tableofcontents que introduz o índice nesse mesmo local.

```
^\s*$ {
    /*
    * An empty line starts the body of the document,
    * so all the headers must come before any empty line
    */
    printf("\\begin{document}");
    stpush(BODY);
}

^=author=\[ stpush(AUTHOR);
    ^=doctype=\[ stpush(DOCTYPE);
    ^=title=\[ stpush(TITLE);
    <UTHOR>[^\]\n]+ printf("\\documentclass{%s}", yytext);
    <TITLE>[^\]\n]+ printf("\\title{%s}", yytext);
<TITLE,AUTHOR,DOCTYPE>\]$ stpop();
```

Figura 4.2: Estados DOCTYPE, TITLE, AUTHOR e BODY

```
<<EOF>> {
    printf("\end{document}");
    /* Se nao acabarmos a funcao, o programa fica em loop */
    return 0;
}
```

Figura 4.3: Fim do documento.

Figura 4.4: Estado BODY e encaminhamento para os diferentes estados.

#### 4.3 Bold e Italic

Nestes 2 casos é feita uma simples substituição dos comandos e escrito tudo o que se encontra entre chavetas (Figura 4.5).

Figura 4.5: BOLD e ITALIC.

#### 4.4 Verbatim

Depois de o analisador léxico encontrar o comando de inicialização substitui pelo correspondente em LATEX e faz ECHO até encontrar o comando de finalização que também substitui pelo correspondente (Figura 4.6).

Figura 4.6: VERBATIM.

#### 4.5 Listas

No estado BODY é encontrada a condição de inicialização de cada um dos três tipos de lista e impresso o respectivo comando de início. Daí o analisador léxico entra no respectivo estado e adiciona os itens no formato pretendido. Ao encontrar o "#"imprime o comando de fecho do comando. Dentro destes três estados também se procura correspondência com os comandos de formatação itálico e bold de forma a poder ser aplicado também em listas (Figura 4.7).

```
<LIST_ITEMIZE>^\.\s* { printf("\\item "); }
<LIST_ENLMERATE>^\.[0-9]+\s* { printf("\\item "); }
<LIST_DESCRIPTION>^\.\[ { printf("\\item "); }
<LIST_DESCRIPTION>^\.\[ { printf("\\item "); }
<LIST_ENLMERATE, LIST_ITEMIZE, LIST_DESCRIPTION>\\bf\{ { printf("\\textbf\{"); stpush(BOLD); }
<LIST_ENLMERATE, LIST_ITEMIZE, LIST_DESCRIPTION>\\it\{ { printf("\\textbf\{"); stpush(ITALIC); }

<LIST_BNUMERATE>^\s=\s* { printf("\\end{enumerate}"); stpop(); }
<LIST_DESCRIPTION>\\s*=\s* { printf("\\end{description}"); stpop(); }
```

Figura 4.7: Listas.

#### 4.6 Secções e Sub-secções

Existe um limite para os níveis de secções que podem ser criadas. Para resolver esse problema criamos uma função que, com auxílio de um apontador para um array de Strings, permite saber que nível pretendemos para imprimir o comando correcto e quando atinge o seu limite (Figura 4.8.

```
/* Supported LaTeX header tags */
static const char * chaps[] = {
    "chapter",
    "section",
    "subsection",
    "subsubsection",
    "paragraph",
    };

/* Number of supported LaTeX header tags */
static const unsigned nc = sizeof(chaps) / sizeof(*chaps);

/* Header level, 0-nc */
int nh = 0;

*}

(a)

<BODY_HEADER>[^#\n] *$ {
    /* Make sure `nh` is in bounds */
    if (((unsigned) — nh) >= nc)
        nh = nc - 1;
    printf("\\%s{%s}\", chaps[nh], yytext);
    nh = 0;
    stpop();
}

(b)
```

Figura 4.8: BODY\_HEADER

Início e Fim do documento No ficheiro flex elaborado optamos por manipulação directa da stack de estados utilizando as funções yy\_push\_state e yy\_pop\_state. Para tal introduzimos "%option stack" para além dos estados por nós definidos, como se pode verificar na Figura 4.9.

Como podemos verificar pela Figura 4.10, ao iniciar, o analisador léxico encontrará a indicação do tipo de documento, titulo e autores e só após encontrar a primeira linha em branco irá passar para o estado BODY que vai conter todo o conteúdo do documento. Encontrando o EOF é introduzido o comando para o fim do documento em LATEX (Figura 4.11).



```
^\s*$ {
    /*
    * An empty line starts the body of the document,
    * so all the headers must come before any empty line
    */
    printf("\begin{document}");
    stpush(BODY);
}
^=author=\[ stpush(AUTHOR);
    ^=doctype=\[ stpush(DOCTYPE);
    ^=title=\[ stpush(TITLE);
    <UTHOR>[^\]\n]+ printf("\\author{%s}", yytext);
    <UTITLE>[^\]\n]+ printf("\\documentclass{%s}", yytext);
    <UTITLE,AUTHOR,DOCTYPE>\]$ stpop();
```

Figura 4.10: Estados DOCTYPE, TITLE, AUTHOR e BODY

Conteúdo do Documento Já dentro do estado BODY, ou seja, dentro do conteúdo do documento, o analisador léxico irá verificar se encontra correspondência para as restantes anotações de forma, conteúdo ou formato que iremos apresentar de seguida. Caso tenha correspondência é encaminhado para o estado devido (Figura 4.12).

#### 4.7 Estruturas de Dados

### 4.8 Algoritmos

Figura 4.12: Estado BODY e encaminhamento para os diferentes estados.

```
<<EOF>> {
    printf("\end{document}");
    /* Se nao acabarmos a funcao, o programa fica em loc
    return 0;
}
```

Figura 4.11: Fim do documento.

# Codificação e Testes

#### 5.1 Testes realizados e Resultados

Nesta secção encontra-se os resultados do nosso analisador léxico no seguinte formato:

- Subsecções que se referem a um tipo de conversão de LS para  $\LaTeX$ ;
- Cada subsecção é formado por duas imagens, onde a da esquerda é o input no do nosso analisador léxico em LSe a da direita é o output em LATEX;

#### 5.1.1 Doctype, Title e Autor

```
=doctype=[report]
=title=[Trabalho 1 (testes)]
=author=[André Sá \and João Bastos \and Pedro Sá]

(a)

\documentclass{report}
\title{Trabalho 1 (testes)}
\author{André Sá \and João Bastos \and Pedro Sá}
\( (b) \)
```

Figura 5.1: Conversão de cabeçalho e preâmbulo

#### 5.1.2 Caracteres Especiais



Figura 5.2: Conversão de cabeçalho e preâmbulo

#### 5.1.3 Lista Numeradas



Figura 5.3: Conversão de lista numeradas

#### 5.1.4 Lista de Itens

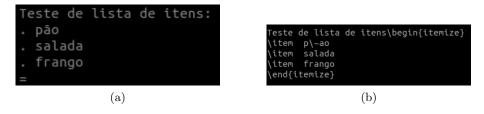


Figura 5.4: Conversão de lista de itens

#### 5.1.5 Lista Descritivas



Figura 5.5: Conversão de lista descritivas

#### 5.1.6 Verbatim

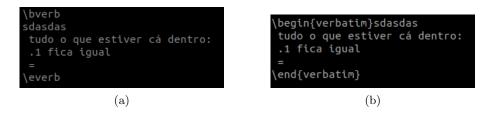


Figura 5.6: Conversão de sintaxe verbatim

#### 5.1.7 Níveis de secção

```
#Primeiro Capítulo
##Secção

Teste de lista enumerada:
.1 Com \bf\bold\} dentro
.2 ponto 2
.3 com \it\text{exto}\ em itálico
.4 outros

###Sub-secção

Teste de lista de itens:
.pão
.salada
.frango
=
####Sub-subsecção

Teste de lista de itens:
.pão
.salada
.frango
=
####Sub-subsecção

Teste de lista descritiva:
.[primeiro] item1
.[segundo] item2
.[outros] item3
=
#####Parágrafo

(a)

\temporto 2
\tem
```

Figura 5.7: Conversão de níveis de secção

# Conclusão

Este projecto mostrou-nos o poder que um analisador léxico tem e que nos pode ser útil em várias situações do diaa-dia, como neste caso do  $\LaTeX$  que é uma linguaguem bastante pesada em termos de sintaxe.

A nossa LS aborda as sintaxes mais usuais de LATEX mas tendo em conta a abrangência de composição de vários tipos de documentos e suporte a várias formas e estruturas de escrita/formatação, o nosso projecto poderá continuar ser desenvolvido para abranger tais sintaxes, e está codificado de forma a ser fácil essa introdução de sintaxe, devido à utilzação da stack.

# Apêndice A

# Código do Programa